

Rapport SAE

ANALYSE EXPLORATOIRE DES DONNEES

ROULA HANI – SENE CLEMENT – SIDIBE FOUSSEYNOU

Table des matières

Le dataset	2
Visualisation	3
Auto-évaluation.....	4

Le dataset

Le dataset est composé de 5000 lignes et 39 colonnes, ce qui correspond à 5000 utilisateurs uniques et 39 variables, ces variables sont utiles pour décrire le comportement des utilisateurs.

Ici le dataset est issu des données d'un réseau social, car nous avons différentes informations qui en font référence tels que :

- les publications (photos_posted, videos_posted, stories_posted)
- les interactions (likes, shared, comments_written, reactions)
- les messages (messages_sent, messages_received)
- le social (nb_friends, nb_groups, nb_pages_followed)
- les déplacements (travels_shared, countries_visited)
- le forfait (subscription, premium_months)
- l'engagement (engagement_score)
- le risque de désabonnement (churn_risk)

On peut également constater dans le dataset des variables qualitatives telles que le genre, la région, le forfait, et le type d'appareil, mais également des variables quantitatives discrètes et continues, en voici quelques-unes :

- les variables quantitatives discrètes : nb_sessions, nb_friends, likes.
- les variables quantitatives continues : time_on_platform, avg_session_duration, churn_risk.


Pendant l'analyse du dataset nous avons constaté plusieurs anomalies, des valeurs vides, des suffixes dérangeants, des valeurs incohérentes, des coordonnées GPS impossibles.

Ces anomalies nous ont poussé à faire du nettoyage de données, voici les opérations menées :

- la suppression de valeurs aberrantes, qui deviennent 'NaN' à l'aide de 'where(condition, pd.Na)'.
- la suppression des suffixes dérangeants (??, abc, ###) présent dans plusieurs lignes, à l'aide de 'str.replace()' pour nettoyer ces valeurs.
- la correction d'âges incohérents, certains âges étaient multipliés par 10 (ex : 220 au lieu de 22), on les a corrigés à l'aide des expressions régulières.
- la correction de valeurs incohérentes comme le churn_risk qui doit être compris entre 0 et 1 car il s'agit d'une probabilité, le score d'engagement entre 20 et 200, les coordonnées GPS dépassant 90 en latitude et 180 en longitude. Ces valeurs ont été remplacées par des NaN.
- le remplacement des valeurs manquantes (NaN) après tous les correctifs par la médiane pour les valeurs numériques et par le mode pour les textes.

Visualisations

1^{er} Visuel :




Le graphique a été conçu à l'aide des variables `age` et `video_views`, et pour réduire les valeurs extrêmes nous avons appliqué une transformation logarithmique, ce qui a permis d'effectuer une régression linéaire sur ces données. Il s'agit d'une droite de régression qui passe au travers d'un nuage de points sur des données modifiées à l'aide de la fonction logarithme, la corrélation étant à 56%, il s'agit donc d'un lien modéré.

La droite est ascendante, donc quand l'âge augmente, le nombre de vidéos visualisées augmente également dans notre cas. Ce qui veut dire que les utilisateurs les plus âgés regardent plus de vidéos.

Cela paraît contre-intuitif, on aurait tendance à penser que les plus jeunes regardent plus de vidéos que les plus âgés, car ils sont nés dans l'ère des réseaux sociaux.

Cette visualisation dans un contexte réel aurait donné lieu à une tendance qui vise les plus âgés concernant le contenu vidéo.

2^{ème} Visuel :




Le graphique a été conçu avec les variables `time_on_platform` et `ads_clicked`. On a utilisé la même méthode que pour le premier visuel pour réduire l'effet des valeurs extrêmes grâce à une transformation logarithmique.

Il s'agit d'un nuage de point avec une droite de régression, avec une corrélation de : 0,77 il s'agit d'un lien fort, donc plus l'utilisateur passe de temps sur la plateforme, plus il est exposé aux publicités.

Dans un contexte réel cette visualisation aurait permis de cibler les publicités par rapports aux types d'utilisateurs qui reste le plus sur la plateforme, car ils génèrent le plus de revenus publicitaires

3^{ème} visuel :



Pour ce 3^{ème} visuel nous avons utilisé la fonction des moindres carrées ordinaires, pour calculer l'influence de chaque variable sur le score d'engagement en minimisant les erreurs entre les valeurs réelles et prédites.

Les barres du graphique indiquent l'effet des variables sélectionnés sur le score d'engagement, une barre verte correspond un impact positif, tandis qu'une rouge correspond à l'inverse.

On remarque que 'photos_posted' et 'likes' influencent positivement sur le score d'engagement, et 'videos_posted' impact négativement sur le score d'engagement.

Dans un contexte réel, cette visualisation pourrait être bénéfique pour une plateforme afin de mettre en place une stratégie plus axé vers les interactions sociales et les photos afin de maximiser la conservation des utilisateurs.

Auto-évaluation

Au regard du travail que nous avons eu à réaliser, à savoir :

- les valeurs incohérentes, les suffixes dérangeants, les autres anomalies ont été nettoyés de manière rigoureuse.
- nous avons normalisés les colonnes (certaines colonnes étaient dans le mauvais format)
- les variables pertinentes ont été utilisés pour obtenir des visualisations
- la mise en relation des coordonnées géographiques qui nous a permis de trouver le mot caché "Peace" qui fut le mot clé de notre dynamique de travail tout au long de cette SAÉ
- les 3 visualisations qui montre les différentes relations fortes entre l'âge et les vidéos, le temps passé sur la plateforme et les publicités, et les actions des utilisateurs sur le score d'engagement.
- l'utilisation de notions mathématiques et statistiques pour analyser le dataset (logarithme, la corrélation, la régression linéaire, les moindres carrés ordinaires)

Et tous les points que nous n'avons pas pu réaliser, par exemple :

- certaines données n'ont pas été entièrement explorées
- certaines relations n'ont pas été analysées.

C'est pour ces raisons que nous nous notons : 10/14.